

1. 进行初始化

传递进来字符串列表后，此时根据模式（w 为词模式，c 为字模式）判断进行词典的初始化。
同时要判断字符是否为汉字，如果不是汉字不记录进入词典

```
class Tokenizer:

    def __init__(self,chars,coding='c',PAD=0) :
        self.chars=chars
        self.coding=coding
        self.PAD=PAD
        self.dict={}
        self.dict["PAD"]=PAD
        self.count=1
        if self.coding == 'c':
            for i in self.chars:
                for j in list(i):
                    if j not in self.dict.keys() and '\u4e00' <= j <= '\u9fff':
                        self.dict[j]=self.count
                        self.count += 1
        else:
            for i in self.chars:
                for j in jieba.lcut(i):
                    if j not in self.dict.keys() and '\u4e00' <= j <= '\u9fff':
                        self.dict[j]=self.count
                        self.count += 1
```

运行结果：

字模式：

```
PS C:\Users\86186\Desktop\现代程序设计\第2章> & "C:\Users\86186\AppData\Local\Programs\Python\Python37\python.exe" "c:\Users\86186\.vscode\extensions\ms-python.python-2021.19.1365161279\pythonFiles\lib\python\debuggy\launcher" '2021' '-.' 'c:\Users\86186\Desktop\现代程序设计\5\tokenizer.py'
{'PAD': 0, '帮': 1, '家': 2, '里': 3, '老': 4, '人': 5, '造': 6, '购': 7, '的': 8, '对': 9, '主': 10, '机': 11, '外': 12, '观': 13, '很': 14, '满': 15, '意': 16, '开': 17, '速': 18, '度': 19, '也': 20, '不': 21, '惜': 22, '运': 23, '行': 24, '声': 25, '音': 26, '小': 27, '能': 28, '时': 29, '没': 30, '发': 31, '现': 32, '什': 33, '么': 34, '问': 35, '题': 36, '希': 37, '望': 38, '可': 39, '以': 40, '用': 41, '住': 42, '性': 43, '能': 44, '挺': 45, '这': 46, '个': 47, '头': 48, '富': 49, '荣': 50, '上': 51, '后': 52, '电': 53, '脑': 54, '复': 55, '活': 56, '了': 57, '原': 58, '先': 59, '卡': 60, '死': 61, '在': 62, '秒': 63, '左': 64, '右': 65, '非': 66, '常': 67, '快': 68, '大': 69, '容': 70, '量': 71, '游': 72, '戏': 73, '美': 74, '道': 75, '真': 76, '粒': 77, '寿': 78, '命': 79, '有': 80, '保': 81, '证': 82, '看': 83, '到': 84, '就': 85, '讨': 86, '厌': 87, '听': 88, '说': 89, '流': 90, '打': 91, '价': 92, '比': 93, '会': 94, '是': 95, '更': 96, '低': 97, '所': 98, '准': 99, '实': 100, '格': 101, '知': 102, '道': 103, '得': 104, '多': 105, '典': 106, '啊': 107, '这': 108, '员': 109, '送': 110, '货': 111, '卖': 112, '物': 113, '整': 114, '休': 115, '警': 116, '服': 117, '务': 118, '态': 119, '还': 120, '吧': 121, '正': 122, '视': 123, '黑': 124, '看': 125, '手': 126, '其': 127, '他': 128, '再': 129, '来': 130, '追': 131, '评': 132, '颜': 133, '值': 134, '高': 135, '纠': 136, '结': 137, '白': 138, '色': 139, '粉': 140, '红': 141, '但': 142, '喜': 143, '次': 144, '刚': 145, '都': 146, '样': 147, '适': 148, '合': 149, '女': 150, '孩': 151, '子': 152, '办': 153, '工': 154, '影': 155, '歌': 156, '尺': 157, '寸': 158, '方': 159, '便': 160, '带': 161, '出': 162, '轻': 163, '薄': 164, '像': 165, '一': 166, '本': 167, '笔': 168, '刷': 169, '包': 170, '精': 171, '致': 172, '位': 173, '好': 174, '大': 175, '棒': 176, '椅': 177, '闪': 178, '店': 179, '客': 180, '给': 181, '高': 182, '赞': 183, '谢': 184, '哦': 185, '优': 186, '惠': 187, '而': 188, '且': 189, '盘': 190, '空': 191, '间': 192, '各': 193, '面': 194, '呢': 195, '巧': 196, '玲': 197, '珑': 198, '安': 199, '零': 200, '两': 201, '金': 202, '属': 203, '定': 204, '制': 205, '企': 206, '业': 207, '盖': 208, '双': 209, '回': 210, '试': 211, '由': 212, '于': 213, '械': 214, '感': 215, '觉': 216, '慢': 217, '加': 218, '跟': 219, '分': 220, '万': 221, '全': 222, '新': 223, '幕': 224, '次': 225, '网': 226, '品': 227, '真': 228, '志': 229, '志': 230, '之': 231, '前': 232, '哪': 233, '牌': 234, '款': 235, '毕': 236, '竟': 237, '我': 238, '种': 239, '钱': 240, '永': 241, '远': 242, '偶': 243, '长': 244, '终': 245, '快': 246, '走': 247, '求': 248, '线': 249, '足': 251, '想': 252, '要': 253, '存': 254, '储': 255, '和': 256, '反': 257, '应': 258, '偶': 259, '尔': 260, '玩': 261, '单': 262, '需': 263, '求': 264, '景': 265, '影': 266, '搭': 267, '载': 268, '那': 269, '域': 270, '清': 271, '屏': 272, '幕': 273, '让': 274, '视': 275, '频': 276, '歌': 277, '音': 278, '爽': 279, '飞': 280, '起': 281, '盖': 282, '另': 283, '奏': 284, '扬': 285, '圆': 286, '热': 287, '情': 288, '耐': 289, '心': 290, '请': 291, '板': 292, '地': 293, '资': 294, '哈': 295, '入': 296, '伙': 297, '伴': 298, '赶': 299, '紧': 300, '你': 301, '们': 302, '配': 303, '宣': 304, '背': 305, '神': 306, '舟': 307, '况': 308, '一': 309, '暗': 310, '影': 311, '精': 312, '代': 313, '随': 314, '味': 315, '播': 316, '砖': 317, '刷': 318, '爆': 319, '现': 320, '点': 321, '瞬': 322, '世': 323, '界': 324, '一': 325, '个': 326, '大': 327, '小': 328, '多': 329, '少': 330, '几': 331, '些': 332, '些': 333, '些': 334, '些': 335, '些': 336, '些': 337, '些': 338, '些': 339, '些': 340, '些': 341, '些': 342, '些': 343, '些': 344, '些': 345, '些': 346, '些': 347, '些': 348, '些': 349, '些': 350, '些': 351, '些': 352, '些': 353, '些': 354, '些': 355, '些': 356, '些': 357, '些': 358, '些': 359, '些': 360, '些': 361, '些': 362, '些': 363, '些': 364, '些': 365, '些': 366, '些': 367, '些': 368, '些': 369, '些': 370, '些': 371, '些': 372, '些': 373, '些': 374, '些': 375, '些': 376, '些': 377, '些': 378, '些': 379, '些': 380, '些': 381, '些': 382, '些': 383, '些': 384, '些': 385, '些': 386, '些': 387, '些': 388, '些': 389, '些': 390, '些': 391, '些': 392, '些': 393, '些': 394, '些': 395, '些': 396, '些': 397, '些': 398, '些': 399, '些': 400, '些': 401, '些': 402, '些': 403, '些': 404, '些': 405, '些': 406, '些': 407, '些': 408, '些': 409, '些': 410, '些': 411, '些': 412, '些': 413, '些': 414, '些': 415, '些': 416, '些': 417, '些': 418, '些': 419, '些': 420, '些': 421, '些': 422, '些': 423, '些': 424, '些': 425, '些': 426, '些': 427, '些': 428, '些': 429, '些': 430, '些': 431, '些': 432, '些': 433, '些': 434, '些': 435, '些': 436, '些': 437, '些': 438, '些': 439, '些': 440, '些': 441, '些': 442, '些': 443, '些': 444, '些': 445, '些': 446, '些': 447, '些': 448, '些': 449, '些': 450, '些': 451, '些': 452, '些': 453, '些': 454, '些': 455, '些': 456, '些': 457, '些': 458, '些': 459, '些': 460, '些': 461, '些': 462, '些': 463, '些': 464, '些': 465, '些': 466, '些': 467, '些': 468, '些': 469, '些': 470, '些': 471, '些': 472, '些': 473, '些': 474, '些': 475, '些': 476, '些': 477, '些': 478, '些': 479, '些': 480, '些': 481, '些': 482, '些': 483, '些': 484, '些': 485, '些': 486, '些': 487, '些': 488, '些': 489, '些': 490, '些': 491, '些': 492, '些': 493, '些': 494, '些': 495, '些': 496, '些': 497, '些': 498, '些': 499, '些': 500, '些': 501, '些': 502, '些': 503, '些': 504, '些': 505, '些': 506, '些': 507, '些': 508, '些': 509, '些': 510, '些': 511, '些': 512, '些': 513, '些': 514, '些': 515, '些': 516, '些': 517, '些': 518, '些': 519, '些': 520, '些': 521, '些': 522, '些': 523, '些': 524, '些': 525, '些': 526, '些': 527, '些': 528, '些': 529, '些': 530, '些': 531, '些': 532, '些': 533, '些': 534, '些': 535, '些': 536, '些': 537, '些': 538, '些': 539, '些': 540, '些': 541, '些': 542, '些': 543, '些': 544, '些': 545, '些': 546, '些': 547, '些': 548, '些': 549, '些': 550, '些': 551, '些': 552, '些': 553, '些': 554, '些': 555, '些': 556, '些': 557, '些': 558, '些': 559, '些': 560, '些': 561, '些': 562, '些': 563, '些': 564, '些': 565, '些': 566, '些': 567, '些': 568, '些': 569, '些': 570, '些': 571, '些': 572, '些': 573, '些': 574, '些': 575, '些': 576, '些': 577, '些': 578, '些': 579, '些': 580, '些': 581, '些': 582, '些': 583, '些': 584, '些': 585, '些': 586, '些': 587, '些': 588, '些': 589, '些': 590, '些': 591, '些': 592, '些': 593, '些': 594, '些': 595, '些': 596, '些': 597, '些': 598, '些': 599, '些': 600, '些': 601, '些': 602, '些': 603, '些': 604, '些': 605, '些': 606, '些': 607, '些': 608, '些': 609, '些': 610, '些': 611, '些': 612, '些': 613, '些': 614, '些': 615, '些': 616, '些': 617, '些': 618, '些': 619, '些': 620, '些': 621, '些': 622, '些': 623, '些': 624, '些': 625, '些': 626, '些': 627, '些': 628, '些': 629, '些': 630, '些': 631, '些': 632, '些': 633, '些': 634, '些': 635, '些': 636, '些': 637, '些': 638, '些': 639, '些': 640, '些': 641, '些': 642, '些': 643, '些': 644, '些': 645, '些': 646, '些': 647, '些': 648, '些': 649, '些': 650, '些': 651, '些': 652, '些': 653, '些': 654, '些': 655, '些': 656, '些': 657, '些': 658, '些': 659, '些': 660, '些': 661, '些': 662, '些': 663, '些': 664, '些': 665, '些': 666, '些': 667, '些': 668, '些': 669, '些': 670, '些': 671, '些': 672, '些': 673, '些': 674, '些': 675, '些': 676, '些': 677, '些': 678, '些': 679, '些': 680, '些': 681, '些': 682, '些': 683, '些': 684, '些': 685, '些': 686, '些': 687, '些': 688, '些': 689, '些': 690, '些': 691, '些': 692, '些': 693, '些': 694, '些': 695, '些': 696, '些': 697, '些': 698, '些': 699, '些': 700, '些': 701, '些': 702, '些': 703, '些': 704, '些': 705, '些': 706, '些': 707, '些': 708, '些': 709, '些': 710, '些': 711, '些': 712, '些': 713, '些': 714, '些': 715, '些': 716, '些': 717, '些': 718, '些': 719, '些': 720, '些': 721, '些': 722, '些': 723, '些': 724, '些': 725, '些': 726, '些': 727, '些': 728, '些': 729, '些': 730, '些': 731, '些': 732, '些': 733, '些': 734, '些': 735, '些': 736, '些': 737, '些': 738, '些': 739, '些': 740, '些': 741, '些': 742, '些': 743, '些': 744, '些': 745, '些': 746, '些': 747, '些': 748, '些': 749, '些': 750, '些': 751, '些': 752, '些': 753, '些': 754, '些': 755, '些': 756, '些': 757, '些': 758, '些': 759, '些': 760, '些': 761, '些': 762, '些': 763, '些': 764, '些': 765, '些': 766, '些': 767, '些': 768, '些': 769, '些': 770, '些': 771, '些': 772, '些': 773, '些': 774, '些': 775, '些': 776, '些': 777, '些': 778, '些': 779, '些': 780, '些': 781, '些': 782, '些': 783, '些': 784, '些': 785, '些': 786, '些': 787, '些': 788, '些': 789, '些': 790, '些': 791, '些': 792, '些': 793, '些': 794, '些': 795, '些': 796, '些': 797, '些': 798, '些': 799, '些': 800, '些': 801, '些': 802, '些': 803, '些': 804, '些': 805, '些': 806, '些': 807, '些': 808, '些': 809, '些': 810, '些': 811, '些': 812, '些': 813, '些': 814, '些': 815, '些': 816, '些': 817, '些': 818, '些': 819, '些': 820, '些': 821, '些': 822, '些': 823, '些': 824, '些': 825, '些': 826, '些': 827, '些': 828, '些': 829, '些': 830, '些': 831, '些': 832, '些': 833, '些': 834, '些': 835, '些': 836, '些': 837, '些': 838, '些': 839, '些': 840, '些': 841, '些': 842, '些': 843, '些': 844, '些': 845, '些': 846, '些': 847, '些': 848, '些': 849, '些': 850, '些': 851, '些': 852, '些': 853, '些': 854, '些': 855, '些': 856, '些': 857, '些': 858, '些': 859, '些': 860, '些': 861, '些': 862, '些': 863, '些': 864, '些': 865, '些': 866, '些': 867, '些': 868, '些': 869, '些': 870, '些': 871, '些': 872, '些': 873, '些': 874, '些': 875, '些': 876, '些': 877, '些': 878, '些': 879, '些': 880, '些': 881, '些': 882, '些': 883, '些': 884, '些': 885, '些': 886, '些': 887, '些': 888, '些': 889, '些': 890, '些': 891, '些': 892, '些': 893, '些': 894, '些': 895, '些': 896, '些': 897, '些': 898, '些': 899, '些': 900, '些': 901, '些': 902, '些': 903, '些': 904, '些': 905, '些': 906, '些': 907, '些': 908, '些': 909, '些': 910, '些': 911, '些': 912, '些': 913, '些': 914, '些': 915, '些': 916, '些': 917, '些': 918, '些': 919, '些': 920, '些': 921, '些': 922, '些': 923, '些': 924, '些': 925, '些': 926, '些': 927, '些': 928, '些': 929, '些': 930, '些': 931, '些': 932, '些': 933, '些': 934, '些': 935, '些': 936, '些': 937, '些': 938, '些': 939, '些': 940, '些': 941, '些': 942, '些': 943, '些': 944, '些': 945, '些': 946, '些': 947, '些': 948, '些': 949, '些': 950, '些': 951, '些': 952, '些': 953, '些': 954, '些': 955, '些': 956, '些': 957, '些': 958, '些': 959, '些': 960, '些': 961, '些': 962, '些': 963, '些': 964, '些': 965, '些': 966, '些': 967, '些': 968, '些': 969, '些': 970, '些': 971, '些': 972, '些': 973, '些': 974, '些': 975, '些': 976, '些': 977, '些': 978, '些': 979, '些': 980, '些': 981, '些': 982, '些': 983, '些': 984, '些': 985, '些': 986, '些': 987, '些': 988, '些': 989, '些': 990, '些': 991, '些': 992, '些': 993, '些': 994, '些': 995, '些': 996, '些': 997, '些': 998, '些': 999, '些': 1000, '些': 1001, '些': 1002, '些': 1003, '些': 1004, '些': 1005, '些': 1006, '些': 1007, '些': 1008, '些': 1009, '些': 1010, '些': 1011, '些': 1012, '些': 1013, '些': 1014, '些': 1015, '些': 1016, '些': 1017, '些': 1018, '些': 1019, '些': 1020, '些': 1021, '些': 1022, '些': 1023, '些': 1024, '些': 1025, '些': 1026, '些': 1027, '些': 1028, '些': 1029, '些': 1030, '些': 1031, '些': 1032, '些': 1033, '些': 1034, '些': 1035, '些': 1036, '些': 1037, '些': 1038, '些': 1039, '些': 1040, '些': 1041, '些': 1042, '些': 1043, '些': 1044, '些': 1045, '些': 1046, '些': 1047, '些': 1048, '些': 1049, '些': 1050, '些': 1051, '些': 1052, '些': 1053, '些': 1054, '些': 1055, '些': 1056, '些': 1057, '些': 1058, '些': 1059, '些': 1060, '些': 1061, '些': 1062, '些': 1063, '些': 1064, '些': 1065, '些': 1066, '些': 1067, '些': 1068, '些': 1069, '些': 1070, '些': 1071, '些': 1072, '些': 1073, '些': 1074, '些': 1075, '些': 1076, '些': 1077, '些': 1078, '些': 1079, '些': 1080, '些': 1081, '些': 1082, '些': 1083, '些': 1084, '些': 1085, '些': 1086, '些': 1087, '些': 1088, '些': 1089, '些': 1090, '些': 1091, '些': 1092, '些': 1093, '些': 1094, '些': 1095, '些': 1096, '些': 1097, '些': 1098, '些': 1099, '些': 1100, '些': 1101, '些': 1102, '些': 1103, '些': 1104, '些': 1105, '些': 1106, '些': 1107, '些': 1108, '些': 1109, '些': 1110, '些': 1111, '些': 1112, '些': 1113, '些': 1114, '些': 1115, '些': 1116, '些': 1117, '些': 1118, '些': 1119, '些': 1120, '些': 1121, '些': 1122, '些': 1123, '些': 1124, '些': 1125, '些': 1126, '些': 1127, '些': 1128, '些': 1129, '些': 1130, '些': 1131, '些': 1132, '些': 1133, '些': 1134, '些': 1135, '些': 1136, '些': 1137, '些': 1138, '些': 1139, '些': 1140, '些': 1141, '些': 1142, '些': 1143, '些': 1144, '些': 1145, '些': 1146, '些': 1147, '些': 1148, '些': 1149, '些': 1150, '些': 1151, '些': 1152, '些': 1153, '些': 1154, '些': 1155, '些': 1156, '些': 1157, '些': 1158, '些': 1159, '些': 1160, '些': 1161, '些': 1162, '些': 1163, '些': 1164, '些': 1165, '些': 1166, '些': 1167, '些': 1168, '些': 1169, '些': 1170, '些': 1171, '些': 1172, '些': 1173, '些': 1174, '些': 1175, '些': 1176, '些': 1177, '些': 1178, '些': 1179, '些': 1180, '些': 1181, '些': 1182, '些': 1183, '些': 1184, '些': 1185, '些': 1186, '些': 1187, '些': 1188, '些': 1189, '些': 1190, '些': 1191, '些': 1192, '些': 1193, '些': 1194, '些': 1195, '些': 1196, '些': 1197, '些': 1198, '些': 1199, '些': 1200, '些': 1201, '些': 1202, '些': 1203, '些': 1204, '些': 1205, '些': 1206, '些': 1207, '些': 1208, '些': 1209, '些': 1210, '些': 1211, '些': 1212, '些': 1213, '些': 1214, '些': 1215, '些': 1216, '些': 1217, '些': 1218, '些': 1219, '些': 1220, '些': 1221, '些': 1222, '些': 1223, '些': 1224, '些': 1225, '些': 1226, '些': 1227, '些': 1228, '些': 1229, '些': 1230, '些': 1231, '些': 1232, '些': 1233, '些': 1234, '些': 1235, '些': 1236, '些': 1237, '些': 1238, '些': 1239, '些': 1240, '些': 1241, '些': 1242, '些': 1243, '些': 1244, '些': 1245, '些': 1246, '些': 1247, '些': 1248, '些': 1249, '些': 1250, '些': 1251, '些': 1252, '些': 1253, '些': 1254, '些': 1255, '些': 1256, '些': 1257, '些': 1258, '些': 1259, '些': 1260, '些': 1261, '些': 1262, '些': 1263, '些': 1264, '些': 1265, '些': 1266, '些': 1267, '些': 1268, '些': 1269, '些': 1270, '些': 1271, '些': 1272, '些': 1273, '些': 1274, '些': 1275, '些': 1276, '些': 1277, '些': 1278, '些': 1279, '些': 1280, '些': 1281, '些': 1282, '些': 1283, '些': 1284, '些': 1285, '些': 1286, '些': 1287, '些': 1288, '些': 1289, '些': 1290, '些': 1291, '些': 1292, '些': 1293, '些': 1294, '些': 1295, '些': 1296, '些': 1297, '些': 1298, '些': 1299, '些': 1300, '些': 1301, '些': 1302, '些': 1303, '些': 1304, '些': 1305, '些': 1306, '些': 1307, '些': 1308, '些': 1309, '些': 1310, '些': 1311, '些': 1312, '些': 1313, '些': 1314, '些': 1315, '些': 1316, '些': 1317, '些': 1318, '些': 1319, '些': 1320, '些': 1321, '些': 1322, '些': 1323, '些': 1324, '些': 1325, '些': 1326, '些': 1327, '些': 1328, '些': 1329, '些': 1330, '些': 1331, '些': 1332, '些': 1333, '些': 1334, '些': 1335, '些': 1336, '些': 1337, '些': 1338, '些': 1339, '些': 1340, '些': 1341, '些': 1342, '些': 1343, '些': 1344, '些': 1345, '些': 1346, '些': 1347, '些': 1348, '些': 1349, '些': 1350, '些': 1351, '些': 1352, '些': 1353, '些': 1354, '些': 1355, '些': 1356, '些': 1357, '些': 1358, '些': 1359, '些': 1360, '些': 1361, '些': 1362, '些': 1363, '些': 1364, '些': 1365, '些': 1366, '些': 1367, '些': 1368, '些': 1369, '些': 1370, '些': 1371, '些': 1372, '些': 1373, '些': 1374, '些': 1375, '些': 1376, '些': 1377, '些': 1378, '些': 1379, '些': 1380, '些': 1381, '些': 1382, '些': 1383, '些': 1384, '些': 1385, '些': 1386, '些': 1387, '些': 1388, '些': 1389, '些': 1390, '些': 1391, '些': 1392, '些': 1393, '些': 1394, '些': 1395, '些': 1396, '些': 1397, '些': 1398, '些': 1399, '些': 1400, '些': 1401, '些': 1402, '些': 1403, '些': 1404, '些': 1405, '些': 1406, '些': 1407, '些': 1408, '些': 1409, '些': 1410, '些': 1411, '些': 1412, '些': 1413, '些': 1414, '些': 1415, '些': 1416, '些': 1417, '些': 1418, '些': 1419, '些': 1420, '些': 1421, '些': 1422, '些': 1423, '些': 1424, '些': 1425, '些': 1426, '些': 1427, '些': 1428, '些': 1429, '些': 1430, '些': 1431, '些': 1432, '些': 1433, '些': 1434, '些': 1
```

2. 2. tokenize(self, sentence) 输入一句话，返回分词(字) 后的字符列表(list_of_chars)。

根据不同的模式进行分词（分字），同时筛选不是汉字的字符

```
def tokenize(self,sentence):
    res=[]
    if self.coding == 'c':
        for i in list(sentence):
            if '\u4e00' <= i <= '\u9fff':
                res.append(i)
    else:
        for i in jieba.lcut(sentence):
            if '\u4e00' <= i <= '\u9fff':
                res.append(i)
    return res
```

运行结果：

字模式：

```
Backend TkAgg is interactive backend. Turning interactive mode on.
PS C:\Users\86186\Desktop\现代程序设计\第2次> c:; cd 'c:\Users\86186\Desktop\现代程序设计\第2次'; & 'C:\Users\86186\AppData\Local\Programs\Python\Python37\python.exe' 'c:\Users\86186\vscode\extensions\ms-python.python-2021.10.1365161279\pythonfiles\lib\python\debugpy\launcher' '2396' '-...' 'c:\Users\86186\Desktop\现代程序设计\5\tokenizer.py'
['很', '好', '的', '一', '次', '购', '物', '下', '单', '后', '秒', '发', '货', '由', '于', '下', '班', '时', '间', '晚', '晚', '上', '了', '才', '开', '始', '装', '客', '服', '都', '很', '配', '合', '的', '指', '导', '安', '装', '问', '了', '很', '多', '问', '题', '售', '后', '客', '服', '都', '很', '有', '耐', '心', '的', '系', '统', '很', '不', '错', '反', '应', '快', '是', '正', '版', '可', '以', '更', '新']
Backend TkAgg is interactive backend. Turning interactive mode on.
```

词模式：

```
Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\86186\AppData\Local\Temp\jieba.cache
Loading model cost 0.793 seconds.
Prefix dict has been built successfully.
['很', '好', '的', '一', '次', '购', '物', '下', '单', '后', '秒', '发', '货', '由', '于', '下', '班', '时', '间', '晚', '晚', '上', '了', '才', '开', '始', '装', '客', '服', '都', '很', '配', '合', '的', '指', '导', '安', '装', '问', '了', '很', '多', '问', '题', '售', '后', '客', '服', '都', '很', '有', '耐', '心', '的', '系', '统', '很', '不', '错', '反', '应', '快', '是', '正', '版', '可', '以', '更', '新']
Backend TkAgg is interactive backend. Turning interactive mode on.
```

3. encode(self, list_of_chars) 输入字符(字或者词) 的字符列表，返回转换后的数字列表 (tokens)

根据词典生成相应的数字列表

```
def encode(self,list_of_chars):
    res=[]
    for i in list_of_chars:
        res.append(self.dict[i])
    return res
```

运行结果：

```
Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\86186\AppData\Local\Temp\jieba.cache
Loading model cost 0.866 seconds.
Prefix dict has been built successfully.
[0, 128, 5, 1087, 96, 1119, 35, 168, 77, 164, 1201, 1202, 891, 38, 433, 1203, 46, 134, 106, 9, 975, 5, 711, 404, 464, 38, 923, 22, 1204, 134, 106, 9, 51, 237, 5, 482, 9, 14, 212, 44, 62, 488, 24, 792]
Backend TMAgg is interactive backend. Turning interactive mode on.
```

- ```
def trim(self,tokens,seq_len):
 while(len(tokens) < seq_len):
 tokens.append(self.PAD)
 while(len(tokens) > seq_len):
 tokens.pop()
 return tokens
```

```
Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\86186\AppData\Local\Temp\jieba.cache
Loading model cost 0.794 seconds.
Prefix dict has been built successfully.
[9, 128, 5, 1087, 96, 1119, 35, 168, 77, 164, 1201, 1202, 891, 38, 433, 1203, 46, 134, 106, 9, 975, 5, 711, 404, 464, 38, 923, 22, 1204, 134, 106, 9, 51, 237, 5, 482, 9, 14,
212, 44, 62, 488, 24, 792, 0]
Backend KAgg is interactive backend. Turning interactive mode on.
```

- ```
def decode(self,tokens):
    res=[]
    ls=list(self.dict.keys())
    for i in tokens:
        res.append(ls[i])

    for j in res:
        print(j,end='')
```


运行结果：

[illegible]

6. `encode_all(self, seq_len)` 返回所有文本 (chars) 的长度为 `seq_len` 的 tokens。

```
def encode_all(self, seq_len):
    res=[]
    for i in self.chars:
        if len(i) == seq_len:
            list_of_chars=self.tokenize(i)
            tokens=self.encode(list_of_chars)
            res.append(self.trim(tokens, len(i)))
    return res
```

运行结果：

```
chars=[]
with open(filepath, 'r', encoding="utf-8") as f:
    for line in f.readlines():
        chars.append(line.strip())

t=Tokenizer(chars, 'w')

list_of_chars=t.tokenize(chars[55])
tokens=t.encode(list_of_chars)
tokens=t.trim(tokens, len(chars[55]))
print(t.encode_all(55))
```

[illegible]

7. seq_len 是句子的长度，实际任务中一般怎么来确定一个合适的长度，请以前次作业中的评论文本或微博文本为例，通过文本的长度分布来进行观察和讨论。
- 在上次作业的基础上，在 plotnodes 模块中加入对文本长度分布的函数，同时在本次作业的环境变量中加入包的路径，导入对应的模块

```
def plotlen(len_list):
    x=list(set(len_list))
    y=[]
    for i in x:
        caly=len_list.count(i)
        y.append(caly)
    x=np.array(x)
    y=np.array(y)
    print(x,y)
    plt.bar(x,y,color='purple')
    plt.xlabel("文本长度")
    plt.ylabel("频数")
    plt.title("文本长度的分布")
    plt.grid(alpha=0.5,linestyle='-.')
    plt.show()
```

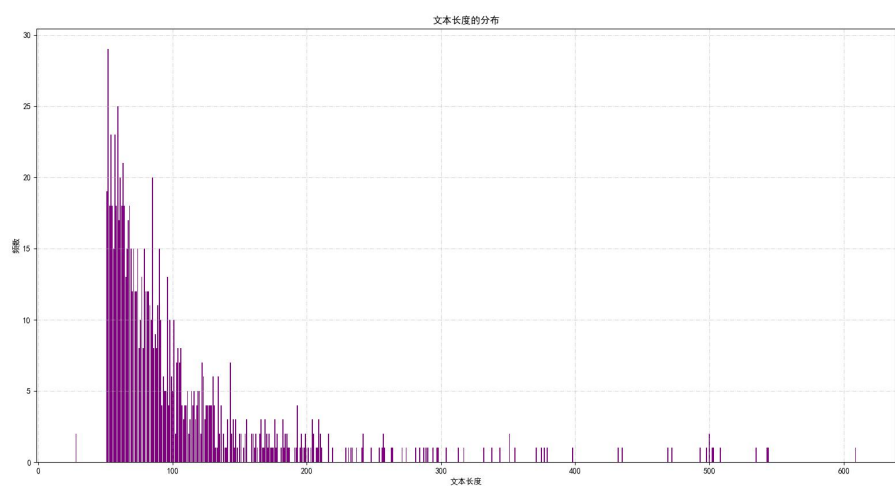
```
import sys
sys.path.append(r"C:\Users\86186\Desktop\现代程序设计\4")

from GraphStat.Visualization import plotnodes
import jieba
```

运行结果：

```
chars=[]
with open(filepath,'r',encoding="utf-8") as f:
    for line in f.readlines():
        chars.append(line.strip())
```

```
len_list=[]
for i in chars:
    len_list.append(len(i))
plotnodes.plotlen(len_list)
```



将图放大可以发现，京东的评论中，长度为 52 的频数最多，为 29 次